


René Fabricius, Fakulta riadenia a informatiky, Žilinská univerzita v Žiline
fabricius@stud.uniza.sk

Cieľom projektu bolo implementovať a použiť metódy na kombinovanie výstupov neurónových sietí. Tieto neurónové siete klasifikovali obrázky z validačnej podmnožiny datasetu ImageNet. Išlo o dataset s 50000 obrázkami v 1000 rozličných triedach. Každá z neurónových sietí vypočítala pre každý klasifikovaný obrázok odhady pravdepodobností jeho príslušnosti do jednotlivých tried. Ako príklad klasifikácie si môžeme ukázať nasledujúci obrázok z ImageNetu.



Správna trieda obrázku: sea anemone, anemone (sasanka)

5 tried s najvyššou pravdepodobnosťou, klasifikované najpresnejšou zo spracovávaných neurónových sietí:

1. starfish, sea star (86.113%)
2. goldfish, *Carassius auratus* (7.665%)
3. sea anemone, anemone (2.777%)
4. axolotl, mud puppy, *Ambystoma mexicanum* (0.901%)
5. sea cucumber, holothurian (0.869%)

Na kombinovanie výstupov neurónových sietí sme použili dve tzv. kombinačné metódy (coupling methods) navrhnuté v [1]. Autori navrhli tieto metódy na spájanie výstupov dvojtriednych klasifikátorov za účelom viactriednej pravdepodobnostnej klasifikácie. Ak máme pozorovanie \mathbf{x} a chceme určiť pravdepodobnosť jeho príslušnosti do k tried, vstupom do spomínaných metód budú odhady r_{ij} párových pravdepodobností $\mu_{ij} = P(y = i | y = i \vee y = j, \mathbf{x})$, kde y je označenie triedy pozorovania \mathbf{x} . Tieto odhady potrebujeme pre každú dvojicu tried $i, j \in \{1, \dots, k\}$, vstup do metód môžeme preto reprezentovať ako maticu $R = (r_{ij})$.

Výstupom metód je potom pravdepodobnostné rozdelenie reprezentované vektorom \mathbf{p} , ktorého prvky predstavujú odhady pravdepodobností $p_i = P(y = i | \mathbf{x}), i = 1, \dots, k$.


Výstupom každej z kombinovaných neurónových sietí je vektor \mathbf{q} , ktorý sa tak isto snaží odhadovať pravdepodobnosti príslušnosti obrázku do jednotlivých tried. Pre každú neurónovú sieť sme z tohto vektora vypočítali maticu podmienených párových pravdepodobností Q zadanú predpisom:

$$Q_{ij} \equiv \begin{cases} q_i / (q_i + q_j), & \text{ak } i \neq j \\ 0, & \text{inak} \end{cases}.$$


Tieto matice sme následne spriemerovali do matice R , ktorá bola vstupom do metód z [1]. Na spriemerovanie matíc Q sme používali dva agregáčne operátory a to priemer a medián. Oba operátory sme na matice aplikovali po prvkoch. Kombináciou týchto dvoch operátorov a dvoch kombinačných metód vznikli štyri **nové klasifikačné algoritmy**, ktoré označujeme: m1_avg, m1_median, m2_avg, m2_median.

Úspešnosť klasifikácie sme vyhodnocovali dvoma spôsobmi. Označené sú ako top1 a top5. Metrika top1 považuje obrázok za správne klasifikovaný, ak trieda, do ktorej patrí, má najvyššiu pravdepodobnosť príslušnosti. Metrike top5 stačí, ak je správna trieda medzi 5 najpravdepodobnejšími. Jedným z dôvodov použitia tejto metriky je, že na ImageNet obrázku sú častokrát viaceré objekty, ako napríklad vidíme na horeuvedenom obrázku, kde je na morskom dne so sasankami spolu aj hviezdica. Všetky klasifikačné algoritmy sme implementovali v programovacom jazyku Python s použitím knižníc numpy a pytorch. Výpočty bežali na školskom serveri s grafickou kartou RTX 2080 Ti a trvali približne dva a pol týždňa.

Celkový počet neurónových sietí, ktorých výstupy sme kombinovali, bol 15. Testovali sme 1260 rôznych podmnožín týchto sietí a vyhodnocovali sme presnosť vzniknutej kombinácie. Tieto podmnožiny nazývame modely. Histogramy presnosti týchto modelov spracovaných vyššie opísanými metódami sú zobrazené na obrázku 1. Čísla na horizontálnych osiach vyjadrujú presnosti modelov, teda aká časť z testovaných obrázkov bola podľa kritéria top5 správne klasifikovaná. Na vertikálnych osiach sú počty modelov, ktoré spadajú do jednotlivých intervalov presnosti. Červenými čiarami sú zobrazené mediány presností jednotlivých metód. Oranžovými čiarami sú zobrazené presnosti modelu, ktorý kombinuje výstupy zo všetkých 15 sietí. Zelenými čiarami sú zobrazené presnosti výstupov jednotlivých neurónových sietí. Podľa mediánu presností je najpresnejšia metóda m2_median.



Obr. 1: Histogramy presností jednotlivých metód na testovaných modeloch



Obr. 2: Závislosť presnosti metódy $m2_median$ od veľkosti modelu

Pri metóde $m2_median$, ktorá sa ukázala podľa mediánu presností ako najpresnejšia, sme otestovali závislosť jej presnosti od veľkosti spracovávaného modelu. Na obrázku vľavo je táto závislosť znázornená pomocou boxplot-ov. Na horizontálnej osi sú počty sietí v modeloch. Na vertikálnej osi je časť testovaných obrázkov, ktorá bola podľa kritéria top5 správne klasifikovaná, teda presnosť modelov. Ako môžeme vidieť, so zväčšujúcou sa veľkosťou modelu, presnosť metódy rastie. Pri väčších modeloch môžeme tiež pozorovať menší rozptyl presností. Za povšimnutie stojí, že najvyššia presnosť modelu bola dosiahnutá s použitím metódy $m2_avg$, išlo o model, ktorý pozostával zo štyroch sietí: DenseNet169, DenseNet201, ResNet152 a Xception.

PodĎakovanie. Tento výskum prebiehal 4.2. - 7.5. 2020 a bol financovaný FRI UNIZA. Implementované klasifikačné algoritmy je možné nájsť v [2].

Referencie

- [1] T.-F. W. et al, *JMLR*, 2004. [Online]. Available: <http://www.jmlr.org/papers/volume5/wu04a/wu04a.pdf>
- [2] R. Fabricius. (2020). [Online]. Available: <https://github.com/ReneFabricius/NNEsembles>